Евгений Борисов

О задаче классификации

разделение данных на части (классы)

```
О задаче классификации
```

```
разделение данных на части (классы)
```

Учебный набор: [ объект, ответ ]

Задача: классификатор

объект → вектор-признак → результат

```
О задаче классификации
```

```
разделение данных на части (классы)
```

```
Учебный набор: [ объект, ответ ]
```

Задача: классификатор

объект → вектор-признак → результат

Обучение: минимизация ошибки

ошибка = результат - правильный ответ

### Критерий остановки:

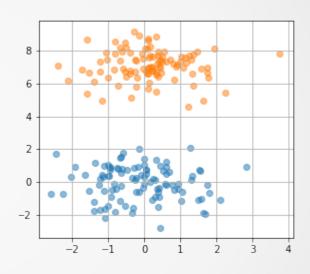
достигнут порог значения ошибки, и/или порог количества циклов

#### О задаче классификации

разделения объектов на части (классы)

$$X \subset \mathbb{R}^n$$
 - объекты

$$Y \in \set{0,1}$$
 - метки классов



#### О задаче классификации

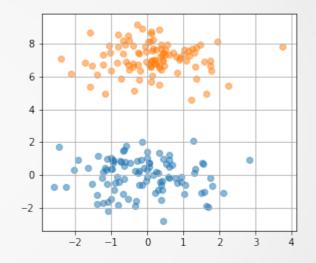
разделения объектов на части (классы)

$$X \subset \mathbb{R}^n$$
 - объекты

$$Y \in \{0,1\}$$
 - метки классов

$$p \in [0,1]$$
 - оценка

 $a: X \rightarrow p$  - считаем оценку



$$y = egin{dcases} 0 \ , p < b \ - \$$
 если оценка выше порога то объект принадлежит «первому» классу

#### метрики качества

```
- погрешность (accuracy)
```

- матрица ошибок ( confusion matrix )
- точность (precision)
- полнота (recall)
- F-мера
- ROC/AUC

#### погрешность (accuracy)

правильные ответы / всего примеров

#### погрешность (accuracy)

правильные ответы / всего примеров

Accuracy это оценка для сбалансированного датасета, т.е. когда количество примеров в классах почти одинаковое

#### погрешность (accuracy)

правильные ответы / всего примеров

Accuracy это оценка для сбалансированного датасета, т.е. когда количество примеров в классах почти одинаковое

Пример: имеем датасет из 203 объектов

#### 1. сбалансированный

100 позитивных 103 негативных

#### 90 правильно предсказанных позитивных

10 ложно-негативных предсказаний 103 правильно предсказанных негативных

193 правильных ответов

193/203 = .95 accuracy

#### погрешность (accuracy)

правильные ответы / всего примеров

Accuracy это оценка для сбалансированного датасета, т.е. когда количество примеров в классах почти одинаковое

Пример: имеем датасет из 203 объектов

#### 1. сбалансированный

100 позитивных 103 негативных

#### 90 правильно предсказанных позитивных

10 ложно-негативных предсказаний 103 правильно предсказанных негативных

193 правильных ответов

193/203 = .95 accuracy

#### 2. несбалансированный

6 позитивных 197 негативных

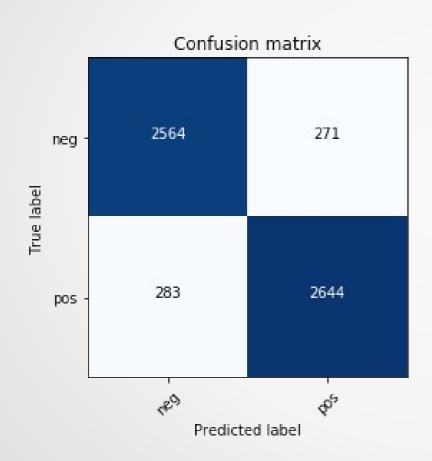
#### 0 правильно предсказанных позитивных

6 ложно-негативных предсказаний 197 правильно предсказанных негативных

197 правильных ответов

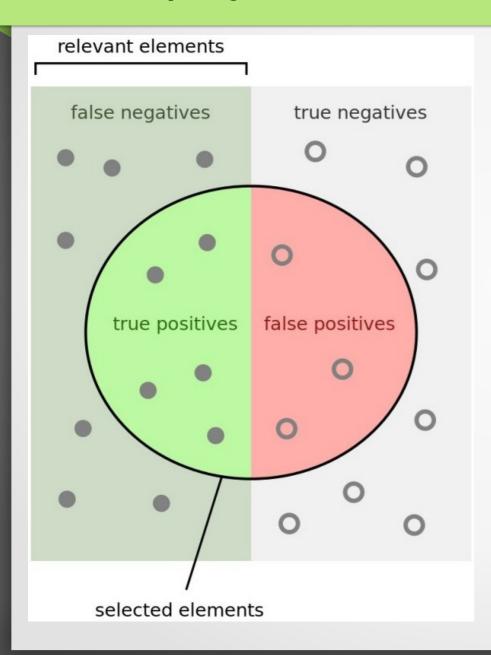
197/203 = .97 accuracy

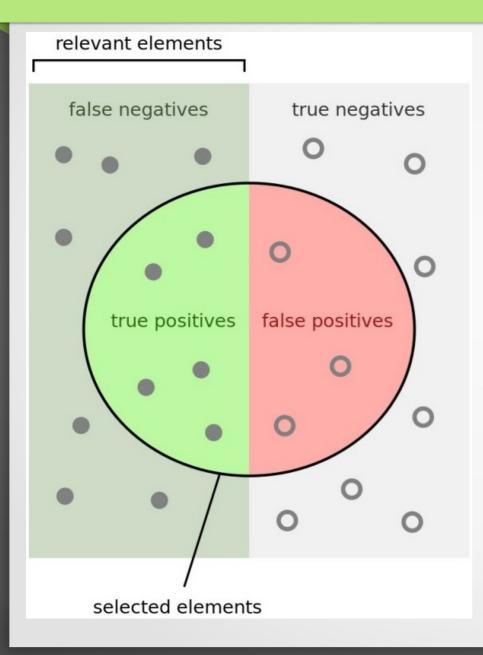
#### матрица ошибок ( confusion matrix )



два класса — четыре группы

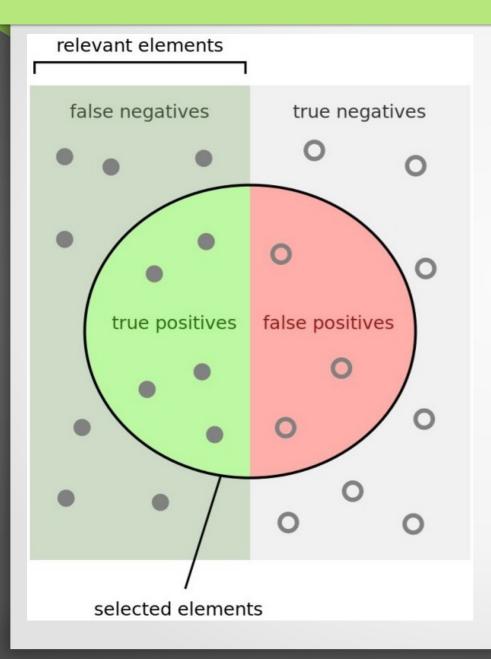
- ТР истинно положительные
- TN истинно отрицательные
- FP ложно положительные
- FN ложно отрицательные

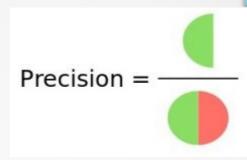






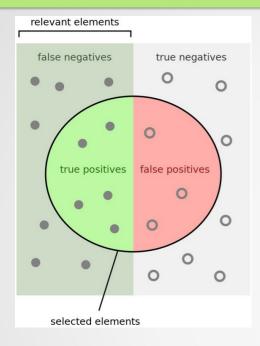
**точность:** доля позитивных объектов среди выделенных моделью



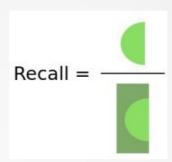


**точность:** доля позитивных объектов среди выделенных моделью

**полнота:** доля найденных моделью объектов среди всех размеченных как позитивные







**accuracy (погрешность)** - общая доля правильных ответов

**precision (точность)** - доля позитивных объектов среди выделенных моделью

recall (полнота) - доля найденных моделью объектов среди всех размеченных как позитивные

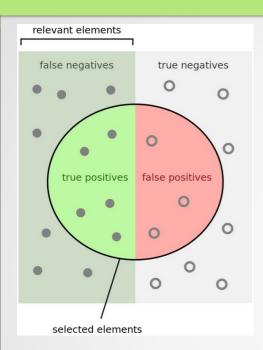
**f1-score** - усреднение точности и полноты

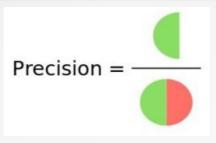
$$Accuracy = rac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = rac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1\text{-}score = rac{2 imes ext{Precision} imes ext{Recall}}{ ext{Precision} + ext{Recall}}$$





$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

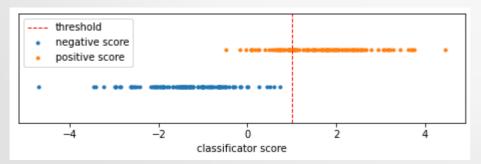
$$Precision = rac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

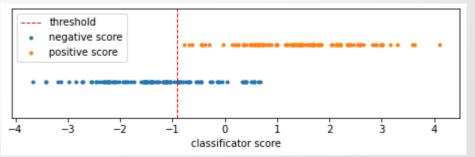
$$F1\text{-}score = \frac{2 \times \operatorname{Precision} \times \operatorname{Recall}}{\operatorname{Precision} + \operatorname{Recall}}$$

#### С ростом полноты точность может снижаться

#### высокая точность positive



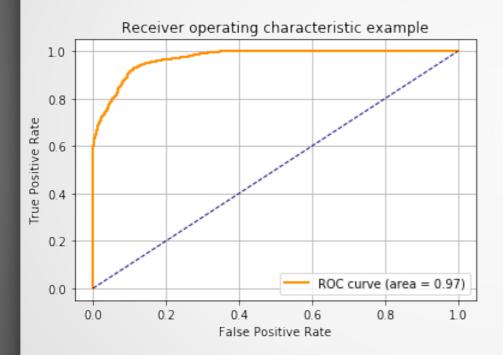
#### большая полнота positive



Пример classification_report				
	precision	recall	f1-score	support
0 1	0.90 0.91	0.90 0.90	0.90 0.91	2835 2927
avg / tota	al 0.90	0.90	0.90	5762

ROC - receiver operating characteristic, рабочая характеристика приёмника

ROC - зависимость полноты (TPR) от доли ложно-негативных (FPR)



**TPR=TP/(TP+FN)** полнота(recall), доля позитивных, найденных классификатором, относительно всех позитивных

FPR=FP/(FP+TN) доля негативных предсказанных неверно

AUC - area under ROC curve, площадь под ROC-кривой характеристика качества классификации

#### способ построения ROC

Таб.1 результаты классификатора

id	оценка	класс
1	0.5	0
2	0.1	0
3	0.2	0
4	0.6	1
5	0.2	1
6	0.3	1
7	0.0	0

Табл. 1

#### способ построения ROC

Таб.1 результаты классификатора

id	оценка	класс
1	0.5	0
2	0.1	0
3	0.2	0
4	0.6	1
5	0.2	1
6	0.3	1
7	0.0	0

Табл. 1

упорядочим строки табл. 1 по убыванию ответов алгоритма

id	оценка	класс
4	0.6	1
1	0.5	0
6	0.3	1
3	0.2	0
5	0.2	1
2	0.1	0
7	0.0	0

Табл. 2

#### способ построения ROC

Таб.1 результаты классификатора

id	оценка	класс
1	0.5	0
2	0.1	0
3	0.2	0
4	0.6	1
5	0.2	1
6	0.3	1
7	0.0	0

Табл. 1

упорядочим строки табл. 1 по убыванию ответов алгоритма

id	оценка	класс
4	0.6	1
1	0.5	0
6	0.3	1
3	0.2	0
5	0.2	1
2	0.1	0
7	0.0	0

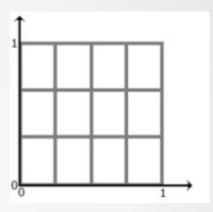
Табл. 2

единичный квадрат на координатной плоскости,

разбить на m равных частей горизонтальными линиями, m - число 1 (m=3),

и на n - вертикальными, n - число нулей (n=4).

получаем сетку на m×n блоков.



#### способ построения ROC

Таб.1 результаты классификатора

id	оценка	класс
1	0.5	0
2	0.1	0
3	0.2	0
4	0.6	1
5	0.2	1
6	0.3	1
7	0.0	0

Табл. 1

упорядочим строки табл. 1 по убыванию ответов алгоритма

id	оценка	класс
4	0.6	1
1	0.5	0
6	0.3	1
3	0.2	0
5	0.2	1
2	0.1	0
7	0.0	0

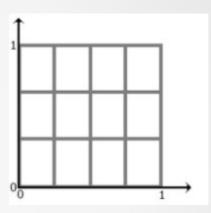
Табл. 2

единичный квадрат на координатной плоскости,

разбить на m равных частей горизонтальными линиями, m - число 1 (m=3),

и на n - вертикальными, n - число нулей (n=4).

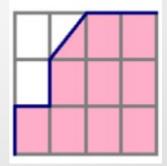
получаем сетку на m×n блоков.



идем по строкам табл. 2 сверху вниз и прорисовывать на сетке линию из точки (0,0).

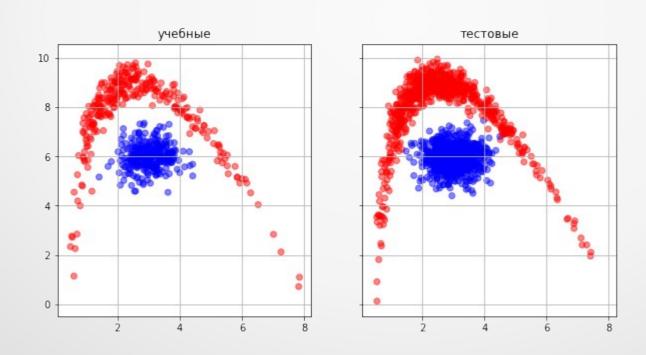
если метка класса 1, то делаем шаг вверх; если 0, то делаем шаг вправо.

если оценки равны, то мы делаем шаг в точку, которая на а блоков выше и b блоков правее, где а – число единиц в группе, b – число нулей в ней.



### разделяем набор данных

- учебный
- тестовый

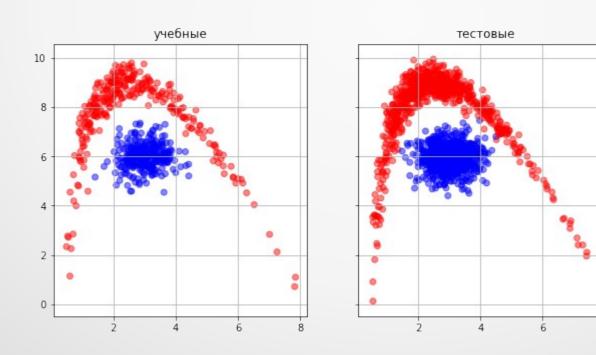


#### разделяем набор данных

- учебный
- тестовый

**недообучение** (underfitting) большая ошибка на учебном наборе

**переобучение** (overfitting) малая ошибка на учебном наборе большая ошибка на тестовом наборе



#### оценка и выбор моделей

формируем 3 набора: учебный / контрольный / тестовый

обучаем на учебном проверяем на контрольном итоговый тест на тестовом



#### оценка и выбор моделей

кроссвалидация (CV)

скользящий контроль - Leave One Out (LOO CV)

$$\mathsf{LOO}(\mu, X^L) = \frac{1}{L} \sum_{i=1}^L Q_{\mu}(X^L \setminus \{x_i\}, \{x_i\})$$

вынимаем пример из учебной выборки обучаем модель без него проверяем ошибку на этом примере

LOO CV это долго

повторяем для всех объектов выборки результат суммируем

#### оценка и выбор моделей

кроссвалидация (CV)

q-fold CV

аналогично LOO, но будем вместо одного объекта использовать подмножество из q объектов

$$\mathsf{CV}_q(\mu, X^L) = rac{1}{q} \sum_{n=1}^q Q_\mu ig( X^L ackslash X_n^{\ell_n}, X_n^{\ell_n} ig)$$

оценка зависит от разбиения на подмножества примеров

#### оценка и выбор моделей

кроссвалидация (CV)

t x q-fold CV

t раз выполняем q-fold CV, учебный набор t раз случайно разбиваем на q блоков

$$\mathsf{CV}_{t\times q}(\mu, X^L) = \frac{1}{t} \sum_{s=1}^t \frac{1}{q} \sum_{n=1}^q Q_\mu \big( X^L \backslash X^{\ell_n}_{sn}, X^{\ell_n}_{sn} \big).$$

# Литература

Борисов E.C. Методы машинного обучения. 2024 https://github.com/mechanoid5/ml\_lectorium\_2024\_I

Машинное обучение для людей https://vas3k.ru/blog/machine learning/

Константин Воронцов - Машинное обучение. ШАД Яндекс https://www.youtube.com/playlist?list=PLJOzdkh8T5kp99tGTEFjH\_b9zqEQiiBtC

Константин Воронцов Машинное\_обучение. курс\_лекций. http://www.machinelearning.ru/wiki/index.php?title=Машинное\_обучение\_(курс\_лекций,\_К.В.Воронцов)

Радослав Нейчев - Машинное обучение, ФПМИ, 2020 https://www.youtube.com/playlist?list=PL4\_hYwCyhAvZyW6qS58x4uElZgAkMVUvj

Александр Дьяконов AUC ROC (площадь под кривой ошибок) https://alexanderdyakonov.wordpress.com/2017/07/28/auc-roc-площадь-под-кривой-ошибок/

MachineLearning.ru: Кривая ошибок <a href="http://www.machinelearning.ru/wiki/index.php?title=ROC-кривая">http://www.machinelearning.ru/wiki/index.php?title=ROC-кривая</a>