

# **Методы восстановления плотности распределения**

Евгений Борисов

# Восстановление плотности

**Вероятностное пространство** математическая модель случайного эксперимента (опыта)

$$(\Omega, \mathcal{A}, P)$$

$\Omega$  - элементарные исходы эксперимента, множество объектов  $\omega$ .

$\mathcal{A}$  - случайные события, набор подмножеств  $\Omega$ .

$\mathcal{A} \ni \Omega$  - достоверное событие

$\mathcal{A} \ni \emptyset$  - невозможное событие

$P$  - функция вероятности  $P: \mathcal{A} \rightarrow [0,1]$

$0 \leq P(a) \leq 1$  вероятность события  $a$  из  $\mathcal{A}$

$P(\emptyset)=0$  ;  $P(\Omega)=1$

**Случайная величина** в пространстве  $(\Omega, \mathcal{A}, P)$  это числовая функция

$$X: \mathcal{A} \rightarrow \mathbb{R}$$

**типы случайных величин:**

дискретные (discrete) - принимающая конечное или счетное число значений  
(Пример: частота слов в тексте, количество детей в семье)

непрерывные (continuous) - принимают значение в определённом интервале  
(Пример: рост людей)

# Восстановление плотности

Вероятностное пространство  $(\Omega, \mathbf{A}, \mathbf{P})$

$\Omega$  - элементарные исходы эксперимента

$\mathbf{A}$  - случайные события, набор подмножеств  $\Omega$

$\mathbf{P}$  - функция вероятности  $\mathbf{P}: \mathbf{A} \rightarrow [0, 1]$

$\mathbf{X}$  - случайная величина  $\mathbf{X}: \mathbf{A} \rightarrow \mathbb{R}$

случайная величина  $\mathbf{X}$  задаётся  
распределением вероятностей  $\mathbf{F}$  своих значений

$$\mathbf{F}(x) = \mathbf{P}( \mathbf{X} \leq x )$$

Рассмотрим интервалы  $(x, x + \Delta x)$ , где  $\Delta x$  - бесконечно малые приращения  $x$  для  $\mathbf{F}(x)$

$$\varphi(x) = \lim_{\Delta x \rightarrow 0} \frac{F(x + \Delta x) - F(x)}{\Delta x}$$

**Плотностью распределения** (вероятности)  $\varphi(x)$  непрерывной случайной величины  $\mathbf{X}$  назовём первую производную функции распределения  $\mathbf{F}(x)$

# Восстановление плотности

**Вероятностное пространство  $(\Omega, \mathcal{A}, P)$**

$\Omega$  - элементарные исходы эксперимента

$\mathcal{A}$  - случайные события, набор подмножеств  $\Omega$

$P$  - функция вероятности  $P: \mathcal{A} \rightarrow [0,1]$

$X$  - случайная величина  $X: \mathcal{A} \rightarrow \mathbb{R}$


$F(x) = P(X \leq x)$  - распределение вероятностей  $P$

$\varphi(x) = F'(x)$  - плотность распределения  $F$




$$P(\Omega) = \int_{-\infty}^{+\infty} \varphi(x) dx = 1$$

**площадь** криволинейной трапеции,  
ограниченной графиком  $\varphi(x)$  и прямыми  $x=a$ ,  $x=b$ ,  $y=0$   
это вероятность  $P(a \leq X \leq b)$  попадания  $X$  в интервал  $[a,b]$



$$P(\alpha \leq X \leq \beta) = \int_{\alpha}^{\beta} \varphi(x) dx$$

**площадь** бесконечной криволинейной трапеции,  
ограниченной графиком  $\varphi(x)$ , прямой  $x=b$ ,  $y=0$   
это функция распределения  $F(b) = P(X \leq b)$



$$F(\beta) = P(X \leq \beta) = \int_{-\infty}^{\beta} \varphi(x) dx$$

# Байесовский классификатор

принцип максимума апостериорной вероятности

$$a(x) = \underset{y \in Y}{\operatorname{argmax}} P(y|x)$$

формула Байеса

$$P(A|B) = \frac{P(A)P(B|A)}{P(B)}$$

байесовский классификатор

$$a(x) = \underset{y \in Y}{\operatorname{argmax}} \lambda_y P(y) p(x|y)$$

$\lambda_y$  - потеря для объектов  $y$

$P(y)$  - доля примеров класса  $y$  (априорная вероятность)

$p(x|y)$  - плотность класса  $y$

# Восстановление плотности

## подходы к оценке плотности распределения

- непараметрический 
$$\hat{p}(x) = \frac{1}{m V(h)} \sum_{j=1}^m K\left(\frac{\rho(x, x_j)}{h}\right)$$
- параметрический 
$$\hat{p}(x) = \varphi(x, \theta)$$
- смеси распределений 
$$\hat{p}(x) = \sum_{j=1}^k w_j \varphi_j(x, \theta_j)$$

# Восстановление плотности

## смеси распределений


$$\hat{p}(x) = \sum_{j=1}^k w_j \varphi_j(x, \theta_j);$$

$$\sum_{j=1}^k w_j = 1; \quad w_j > 0$$

# Восстановление плотности

## ЕМ (expectation-maximization algorithm):

базовый вариант алгоритма





# Восстановление плотности

**ЕМ (expectation-maximization algorithm)**

оценка

$$g_{ij} = \frac{w_j \varphi_j(x_i, \theta_j)}{\sum_{k=1}^s w_k \varphi_k(x_i, \theta_k)}$$

$i=1\dots m$

$m$  - количество примеров  $X$

$s$  - количество компонент смеси

# Восстановление плотности

## ЕМ (expectation-maximization algorithm)

оценка

$$g_{ij} = \frac{w_j \varphi_j(x_i, \theta_j)}{\sum_{k=1}^s w_k \varphi_k(x_i, \theta_k)}$$

$i=1\dots m$

$m$  - количество примеров  $X$

$s$  - количество компонент смеси

коррекция

$$w_j = \frac{1}{m} \sum_{i=1}^m g_{ij}$$

$$\theta_j = \underset{\theta}{\operatorname{argmax}} \sum_{i=1}^m g_{ij} \ln \varphi_j(x_i, \theta)$$

# Восстановление плотности

## ЕМ (expectation-maximization algorithm)

оценка

$$g_{ij} = \frac{w_j \varphi_j(x_i, \theta_j)}{\sum_{k=1}^s w_k \varphi_k(x_i, \theta_k)}$$

$i=1\dots m$

$m$  - количество примеров  $X$

$s$  - количество компонент смеси

коррекция

$$w_j = \frac{1}{m} \sum_{i=1}^m g_{ij}$$

$$\theta_j = \underset{\theta}{\operatorname{argmax}} \sum_{i=1}^m g_{ij} \ln \varphi_j(x_i, \theta)$$


условие остановки: параметры не изменились

$$|g_{ij}(t-1) - g_{ij}(t)| < \delta; 0 < \delta < 1$$

# Восстановление плотности

**параметрический подход:**

допустим -  $p(\mathbf{x})$  это нормальная  $n$ -мерная плотность



$$p(\mathbf{x}) = \frac{\exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)}{\sqrt{(2\pi)^n \det \boldsymbol{\Sigma}}}$$

# Восстановление плотности

**ЕМ** для нормальной плотности

$$p(x) = \sum_k w_k N(x; \Sigma_k, \mu_k)$$

n-мерная гауссовская плотность

$$p(x) = N(x; \Sigma, \mu) = \frac{\exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right)}{\sqrt{(2\pi)^n \det \Sigma}}$$

оценки параметров для максимального правдоподобия  
имеют следующий вид

мат.ожидание

$$\hat{\mu} = \frac{1}{m} \sum_{i=1}^m x_i$$

матрица ковариаций

$$\hat{\Sigma} = \frac{1}{m} \sum_{i=1}^m (x_i - \hat{\mu})(x_i - \hat{\mu})^T$$

# Восстановление плотности

**ЕМ** для нормальной плотности

$$p(x) = \sum_k w_k N(x; \Sigma_k, \mu_k)$$

оценка:

$$g_{ij} = \frac{w_j N(x_i; \Sigma_j, \mu_j)}{\sum_k w_k N(x_i; \Sigma_k, \mu_k)}$$

$$N(x; \Sigma, \mu) = \frac{\exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right)}{\sqrt{(2\pi)^n \det \Sigma}}$$

задача:

$$\Sigma_j, \mu_j = \underset{\Sigma, \mu}{\operatorname{argmax}} \sum_{i=1}^m g_{ij} \ln N(x_i; \Sigma, \mu)$$

# Восстановление плотности

**ЕМ** для нормальной плотности

$$p(x) = \sum_k w_k N(x; \Sigma_k, \mu_k)$$

оценка:

$$g_{ij} = \frac{w_j N(x_i; \Sigma_j, \mu_j)}{\sum_k w_k N(x_i; \Sigma_k, \mu_k)}$$

$$N(x; \Sigma, \mu) = \frac{\exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right)}{\sqrt{(2\pi)^n \det \Sigma}}$$

задача:

$$\Sigma_j, \mu_j = \underset{\Sigma, \mu}{\operatorname{argmax}} \sum_{i=1}^m g_{ij} \ln N(x_i; \Sigma, \mu)$$

коррекция:

$$w_j = \frac{1}{m} \sum_{i=1}^m N_j$$

$$N_j = \sum_{i=1}^m g_{ij}$$

ВЕС КОМПОНЕНТЫ

# Восстановление плотности

**ЕМ** для нормальной плотности

$$p(x) = \sum_k w_k N(x; \Sigma_k, \mu_k)$$

оценка: 
$$g_{ij} = \frac{w_j N(x_i; \Sigma_j, \mu_j)}{\sum_k w_k N(x_i; \Sigma_k, \mu_k)}$$

$$N(x; \Sigma, \mu) = \frac{\exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right)}{\sqrt{(2\pi)^n \det \Sigma}}$$

задача: 
$$\Sigma_j, \mu_j = \underset{\Sigma, \mu}{\operatorname{argmax}} \sum_{i=1}^m g_{ij} \ln N(x_i; \Sigma, \mu)$$

коррекция:

$$w_j = \frac{1}{m} \sum_{i=1}^m N_j$$

вес компоненты

$$N_j = \sum_{i=1}^m g_{ij}$$

$$\mu_j = \frac{1}{N_j} \sum_{i=1}^m g_{ij} x_i$$

Мат. ожидание компоненты



# Восстановление плотности

**ЕМ** для нормальной плотности

$$p(x) = \sum_k w_k N(x; \Sigma_k, \mu_k)$$

оценка:

$$g_{ij} = \frac{w_j N(x_i; \Sigma_j, \mu_j)}{\sum_k w_k N(x_i; \Sigma_k, \mu_k)}$$

$$N(x; \Sigma, \mu) = \frac{\exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right)}{\sqrt{(2\pi)^n \det \Sigma}}$$

задача:

$$\Sigma_j, \mu_j = \underset{\Sigma, \mu}{\operatorname{argmax}} \sum_{i=1}^m g_{ij} \ln N(x_i; \Sigma, \mu)$$

коррекция:

$$w_j = \frac{1}{m} \sum_{i=1}^m N_j$$

вес компоненты

$$N_j = \sum_{i=1}^m g_{ij}$$

$$\mu_j = \frac{1}{N_j} \sum_{i=1}^m g_{ij} x_i$$

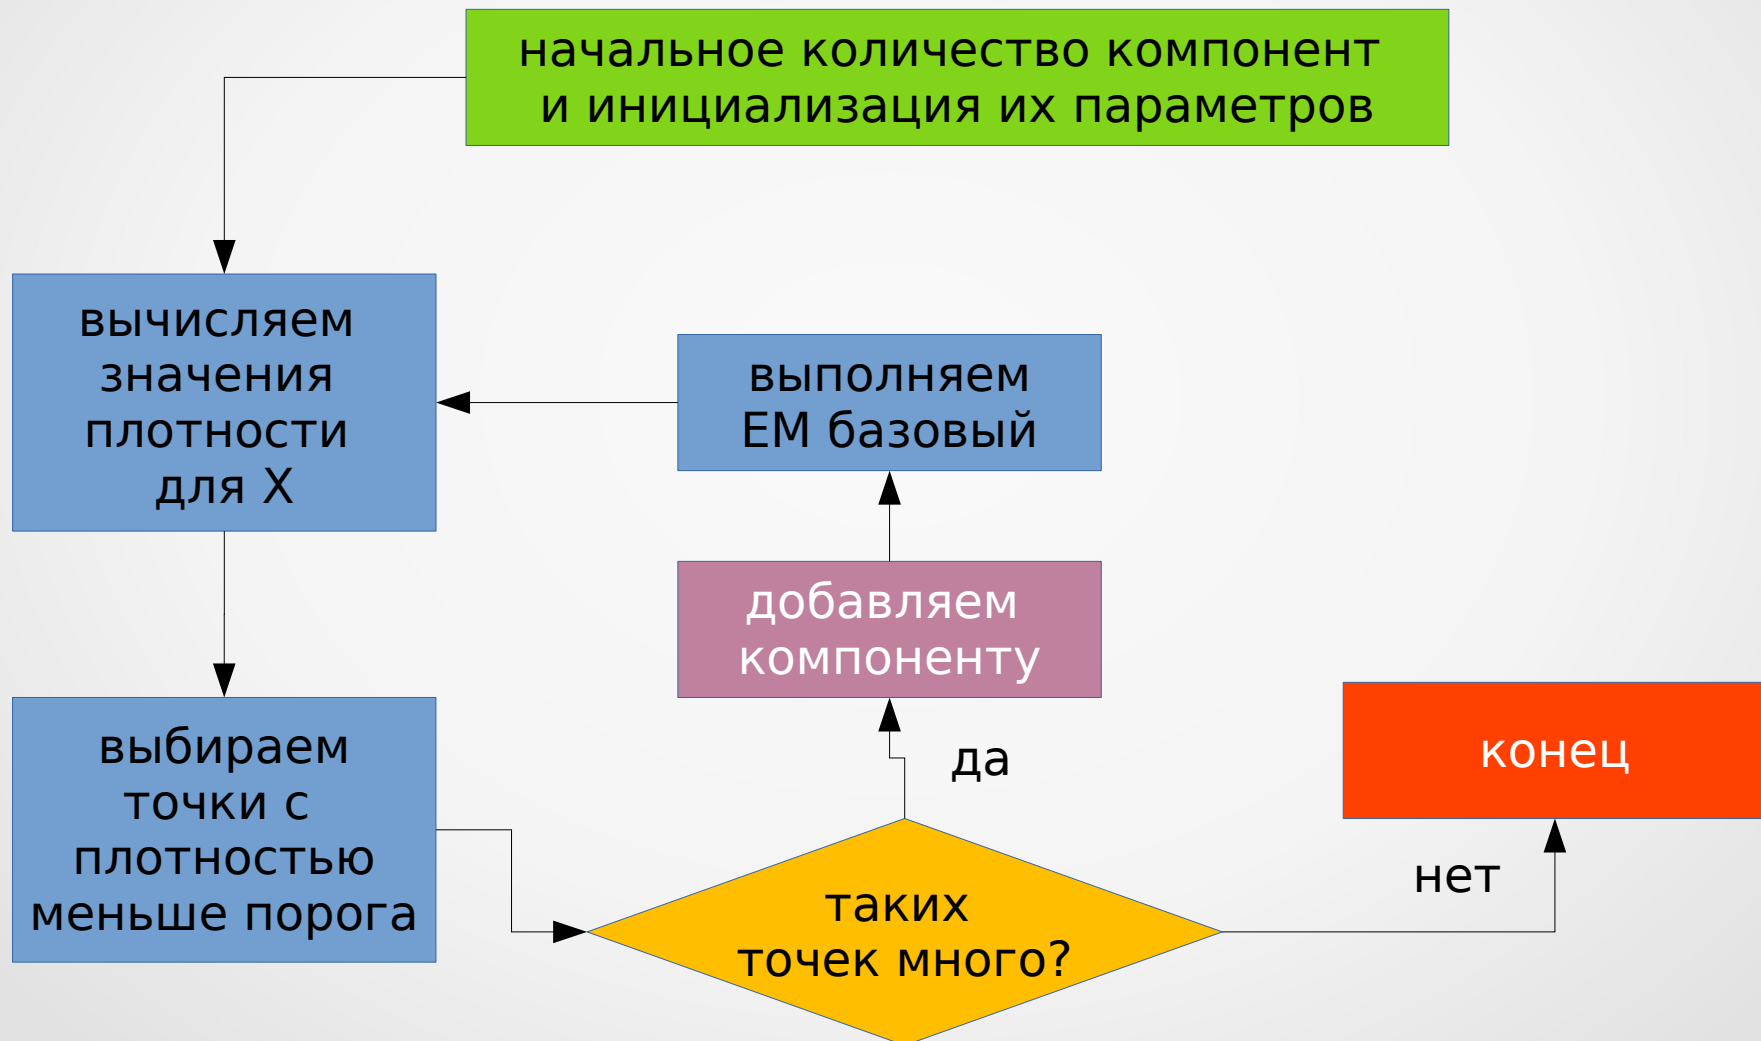
мат.ожидание компоненты

$$\Sigma_j = \frac{1}{c N_j} \sum_{i=1}^m g_{ij} (x_i - \mu_j)^T (x_i - \mu_j); 0 < c \leq 1$$

матрица ковариаций компоненты

# Восстановление плотности

## ЕМ с последовательным добавлением компонент



# Восстановление плотности

**ЕМ** последовательное добавление компонент  
(для нормальной плотности)

начальные значения параметров первой компоненты смеси

$$w_1 = 1$$

вес компоненты

$$\Sigma_1 = \text{cov}(X)$$

матрица ковариаций  
компоненты

$$\mu_1 = \frac{1}{|X|} \sum X$$

мат.ожидание  
компоненты

# Восстановление плотности

**ЕМ** последовательное добавление компонент  
(для нормальной плотности)

$X_{low} \subset X$  - точки с правдоподобием (значением смеси) ниже порога

начальные значения параметров новой компоненты смеси

$$w_{k+1} = \frac{|X_{low}|}{|X|}$$

вес компоненты

$$\Sigma_{k+1} = cov(X_{low})$$

матрица ковариаций  
компоненты

$$\mu_{k+1} = w_{k+1} \frac{1}{|X_{low}|} \sum X_{low}$$

мат.ожидание  
компоненты

# Восстановление плотности

**ЕМ** последовательное добавление компонент  
(для нормальной плотности)

$X_{low} \subset X$  - точки с правдоподобием (значением смеси) ниже порога

начальные значения параметров новой компоненты смеси

$$w_{k+1} = \frac{|X_{low}|}{|X|}$$

вес компоненты

$$\Sigma_{k+1} = \text{cov}(X_{low})$$

матрица ковариаций  
компоненты

$$\mu_{k+1} = w_{k+1} \frac{1}{|X_{low}|} \sum X_{low}$$

мат.ожидание  
компоненты

коррекция весов старых компонент смеси

$$w_i := w_i (1 - w_{k+1})$$


после определения новых параметров смеси запускаем ЕМ

# Восстановление плотности

**RBF** - сеть радиальных базисных функций

Байесовский классификатор

плотности классов - смеси нормальных распределений




$$a(x) = \underset{y \in Y}{\operatorname{argmax}} \lambda_y P(y) p(x|y)$$

$$p(x|y) = \sum_k w_k^y \varphi_k^y(x; \theta_k^y) = \sum_k w_k^y N(x; \Sigma_k^y, \mu_k^y)$$

[http://www.machinelearning.ru/wiki/index.php?title=Сеть\\_радиальных\\_базисных\\_функций](http://www.machinelearning.ru/wiki/index.php?title=Сеть_радиальных_базисных_функций)

# Восстановление плотности

**Пример:** детектор новых объектов для неподвижных камер



# Литература

Борисов Е.С. Методы машинного обучения. 2024

[https://github.com/mechanoid5/ml\\_lectorium\\_2024\\_I](https://github.com/mechanoid5/ml_lectorium_2024_I)

Константин Воронцов Машинное обучение. ШАД Яндекс

[https://www.youtube.com/playlist?list=PLJOzdkh8T5kp99tGTEFjH\\_b9zqEQiiBtC](https://www.youtube.com/playlist?list=PLJOzdkh8T5kp99tGTEFjH_b9zqEQiiBtC)

Константин Воронцов Машинное\_обучение. курс\_лекций.

[http://www.machinelearning.ru/wiki/index.php?title=Машинное\\_обучение\\_\(курс\\_лекций,\\_К.В.Воронцов\)](http://www.machinelearning.ru/wiki/index.php?title=Машинное_обучение_(курс_лекций,_К.В.Воронцов))

SciKit-Learn : Naive Bayes

[https://scikit-learn.org/stable/modules/naive\\_bayes.html](https://scikit-learn.org/stable/modules/naive_bayes.html)

Евгений Борисов Детектор объектов для неподвижных камер.

<http://mechanoid.su/cv-backgr.html>