Евгений Борисов

#### методы ML

- метрические измеряем расстояния, определить ближайших
- *погические* построить правило (комбинацию предикатов)
- статистические восстановить плотность, определить вероятность
- линейные построить разделяющую поверхность
- композиции собрать несколько классификаторов в один

моделируем логику человеческих решений

интерпретируемость (для некоторых приложений это критично)

### предикат - «простое» правило для выделения объектов

- предикат может быть описан естественным языком
- достаточно простая формула
- зависит от небольшого числа признаков

### предикат - «простое» правило для выделения объектов

- предикат может быть описан естественным языком
- достаточно простая формула
- зависит от небольшого числа признаков

$$(x_1 > 10) \land (x_2 < 3) \lor \neg x_3$$

#### предикат - «простое» правило для выделения объектов

- предикат может быть описан естественным языком
- достаточно простая формула
- зависит от небольшого числа признаков

$$(x_1>10)\land(x_2<3)\lor \neg x_3$$

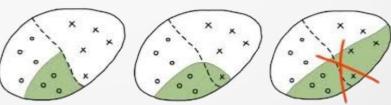
• должен быть информативен, т.е. выделяет некоторое количество объектов одного класса

#### предикат - «простое» правило для выделения объектов

- предикат может быть описан естественным языком
- достаточно простая формула
- зависит от небольшого числа признаков

$$(x_1 > 10) \land (x_2 < 3) \lor \neg x_3$$

• должен быть информативен, т.е. выделяет некоторое количество объектов одного класса



• идея: покрыть весь датасет предикатами, получим классификатор

#### закономерность - набор правил (предикатов)

- конъюнкция  $R(x) = \Lambda_i [a_i \leq f_i(x) < b_i]$
- синдром  $R(x) = \left[\sum_{i} \left[a_i \leqslant f_i(x) < b_i\right] > d\right]$
- полуплоскость  $R(x) = \left[\sum_{i} w_{i} \cdot f_{i}(x) \geqslant w_{0}\right]$
- wap  $R(x) = [\rho(x_0, x) \leq w_0]$

#### закономерность - набор правил (предикатов)

- конъюнкция  $R(x) = \Lambda_i [a_i \leqslant f_i(x) < b_i]$
- синдром  $R(x) = \left[\sum_{i} \left[a_i \leqslant f_i(x) < b_i\right] > d\right]$
- полуплоскость  $R(x) = \left[\sum_i w_i \cdot f_i(x) \geqslant w_0\right]$
- шар  $R(x) = [\rho(x_0, x) \leq w_0]$

задача: нужно отбирать «хорошие» закономерности

вопрос: как оценивать закономерности?

задача: нужно отбирать «хорошие» закономерности

вопрос: как оценивать закономерности?

введём понятие информативности

### информативность - энтропийный критерий

два исхода с вероятностями q и 1-q

количество информации:  $I_1 = -\log_2(q)$ ;  $I_0 = -\log_2(1-q)$ 

энтропия - математическое ожидание количества

информации  $h(q) \!=\! -q \cdot \! \log_2(q) \!-\! (1\!-\!q) \cdot \! \log_2(1\!-\!q)$ 

### информативность - энтропийный критерий

два исхода с вероятностями q и 1-q

количество информации:  $I_1 = -\log_2(q)$ ;  $I_0 = -\log_2(1-q)$ 

энтропия - математическое ожидание количества информации  $h(q) \! = \! -q \! \cdot \! \log_2(q) \! - \! (1 \! - \! q) \! \cdot \! \log_2(1 \! - \! q)$ 

### энтропия выборки:

исходы q это позитивно размеченные объекты (класса y)

 $H(y) = h\left(\frac{P}{S}\right)$  Р - количество позитивных объектов

S - общее количество объектов

### информативность - энтропийный критерий

энтропия выборки:

исходы q это позитивно размеченные объекты (класса y)

$$H(y)=h\left(\frac{P}{S}\right)$$

Р - количество позитивных объектов

S - общее количество объектов

### предикат **R** выделил объекты

р - количество позитивных

n - количество негативных

### энтропия выборки после получения информации **R**

$$H(y|R) = \frac{(p+n)}{S} \cdot h\left(\frac{p}{p+n}\right) + \frac{s-p-n}{S} \cdot h\left(\frac{P-p}{S-p-n}\right)$$

### информативность - энтропийный критерий

энтропия выборки:

исходы q это позитивно размеченные объекты (класса y)

$$H(y)=h\left(\frac{P}{S}\right)$$

Р - количество позитивных объектов

S - общее количество объектов

### предикат **R** выделил объекты

р - количество позитивных

n - количество негативных

### энтропия выборки после получения информации **R**

$$H(y|R) = \frac{(p+n)}{S} \cdot h\left(\frac{p}{p+n}\right) + \frac{s-p-n}{S} \cdot h\left(\frac{P-p}{S-p-n}\right)$$

информационный выигрыш (Information gain)

$$iGain(y,R)=H(y)-H(y|R)$$

#### основные вопросы построения логического классификатора

- как извлекать признаки <u>не наука, но творчество</u>
- какого вида закономерности нужны простые, малое количество признаков
- как определить информативность iGain, ...
- как искать закономерности ограниченный перебор (rule induction)
- как объединить закономерности в алгоритм

#### как объединить закономерности в алгоритм:

решающее дерево

рекурсивное разделение данных на две части

строим простой предикат ищем признак **i** и порог **b** для него

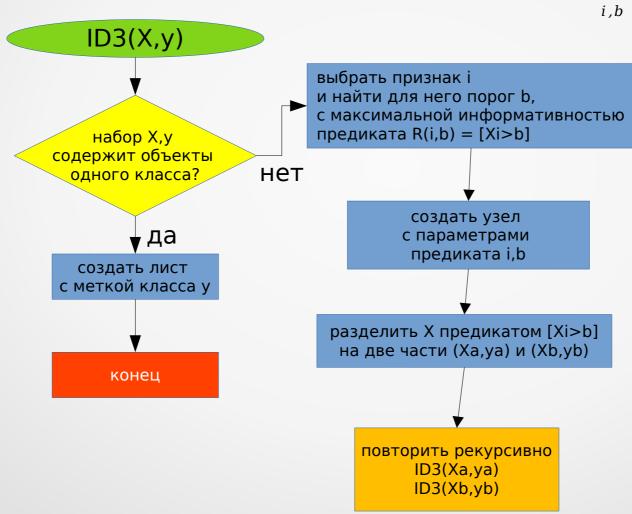
максимизируем информативность

$$\max_{i,b} |iGain(y,[X_i>b])|$$

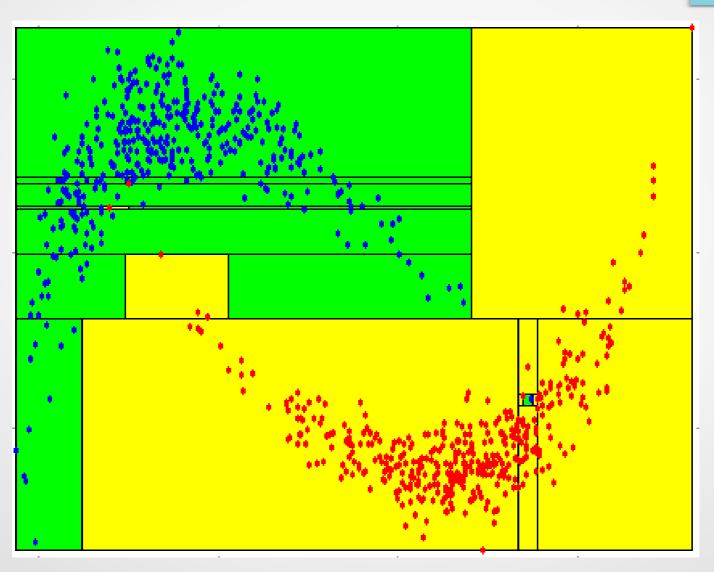
#### как объединить закономерности в алгоритм:

решающее дерево, алгоритм ID3

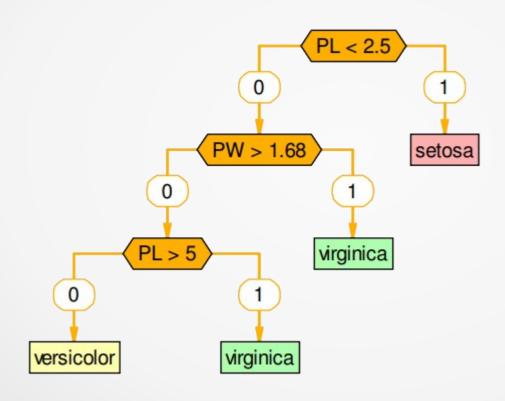
 $\max_{i,b} (iGain(y,[X_i>b]))$ 



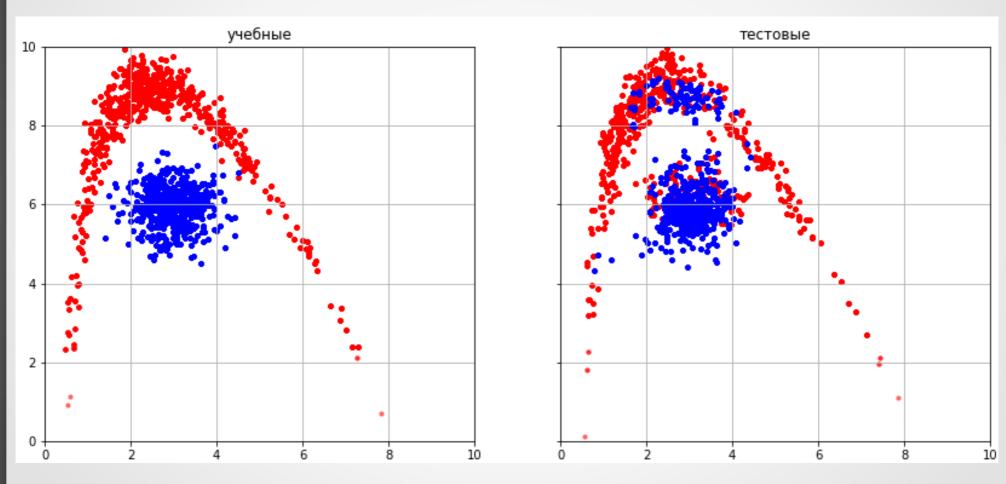
разделение набора объектов решающим деревом



пример дерева для набора iris



результат работы решающего дерева



на учебном наборе - 100% точность

на тесте - переобучение

#### решающее дерево

достоинство: интерпретируемость результата

недостаток: переобучение, неустойчивы к шуму

### pruning - обрезка решающего дерева

<u>pre-pruning</u> – критерий раннего останова. *если* информативность меньше порога или глубина велика *то* прекращаем ветвление

<u>post-pruning</u> – пост-редукция. просматриваем все внутренние вершины дерева проверяем их качество на тестовой выборке, заменяем листом, где качество после разделения ухудшается

# Литература

Борисов E.C. Методы машинного обучения. 2024 https://github.com/mechanoid5/ml\_lectorium\_2024\_I

Константин Воронцов Машинное обучение. ШАД Яндекс https://www.youtube.com/playlist?list=PLJOzdkh8T5kp99tGTEFjH\_b9zqEQiiBtC

SciKit-Learn : Decision Trees

https://scikit-learn.org/stable/modules/tree.html