Евгений Борисов

Языковая модель

- предсказываем следующее слово на основе предыдущих
- оценка (вероятность) совместимости цепочки слов

Оценка цепочки слов (биграммная модель):

$$p(w_1...w_n) = \prod_{k=1}^{n} p(w_k|w_{k-1})$$

$$p(w_n|w_{n-1}) = \frac{C(w_{n-1}w_n)}{C(w_{n-1})}$$

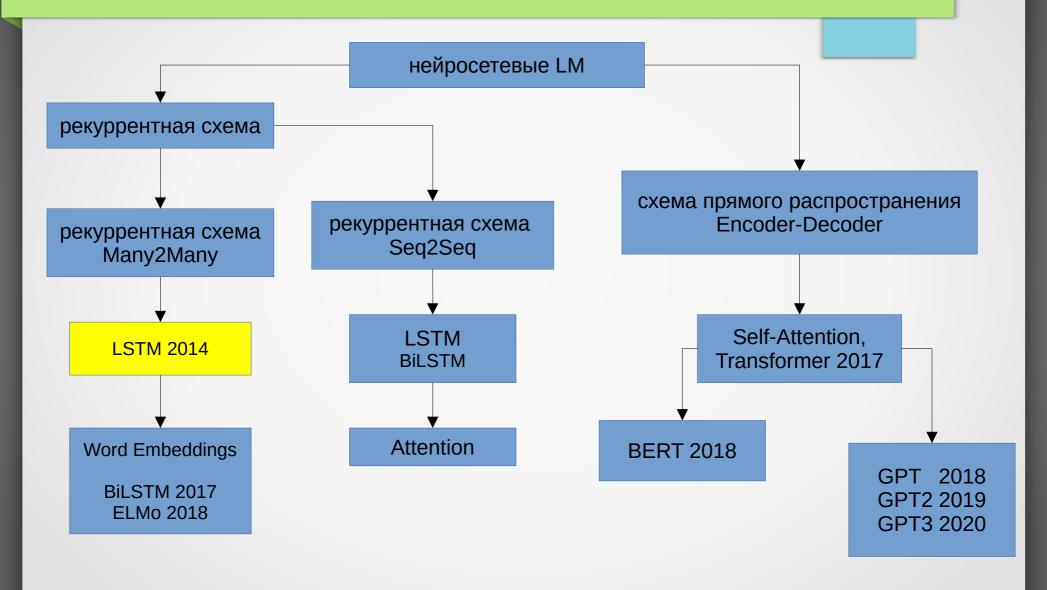
Р - вероятность совместного использования слов

C(w) — количество слов w в тексте

Языковые модели

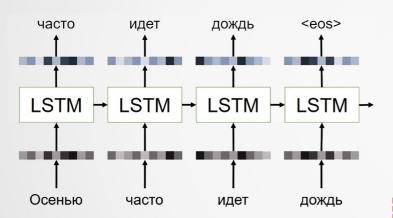
нейросетевая языковая модель (word based model)

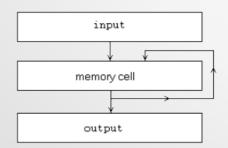
- из текстов собираем пары [[контекст], слово]
- обучаем RNN по контексту определять слово input -> LSTM -> softmax

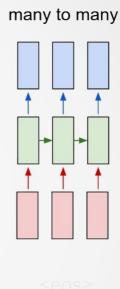


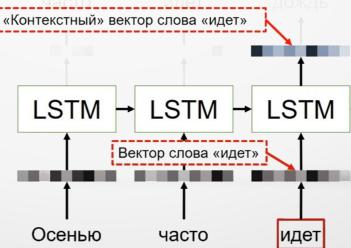
Простая схема с рекуррентной сетью

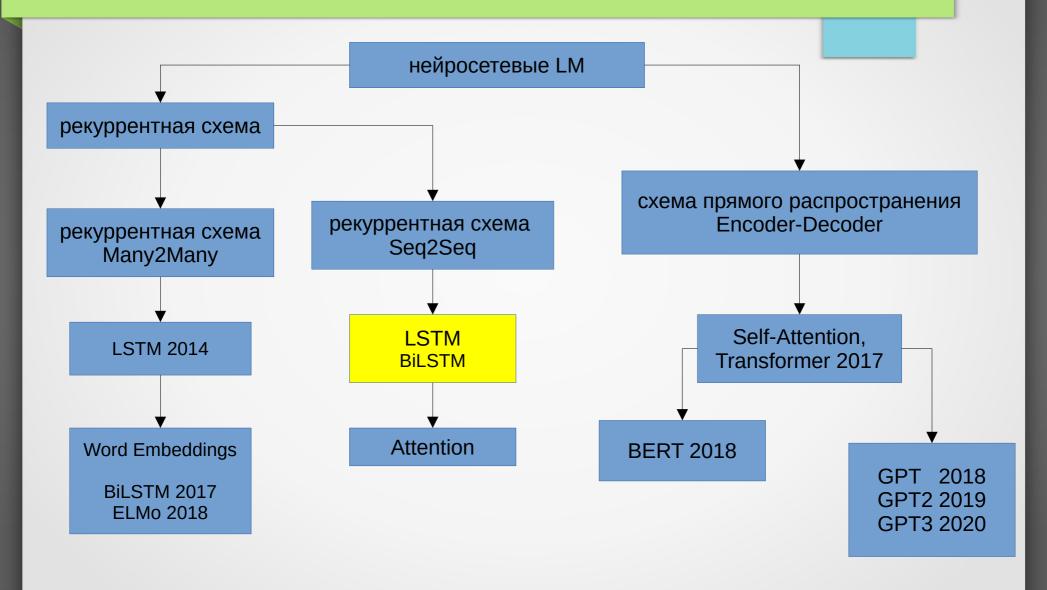
Предсказываем следующее слово по предыдущему контексту получаем word embedding, который учитывает левый контекст



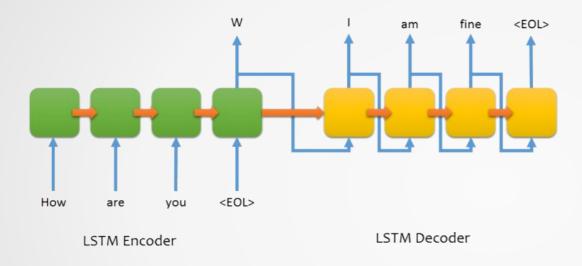






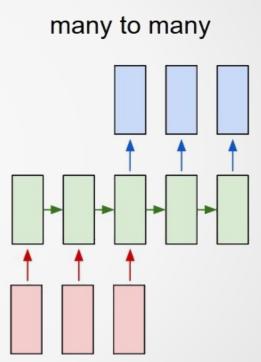


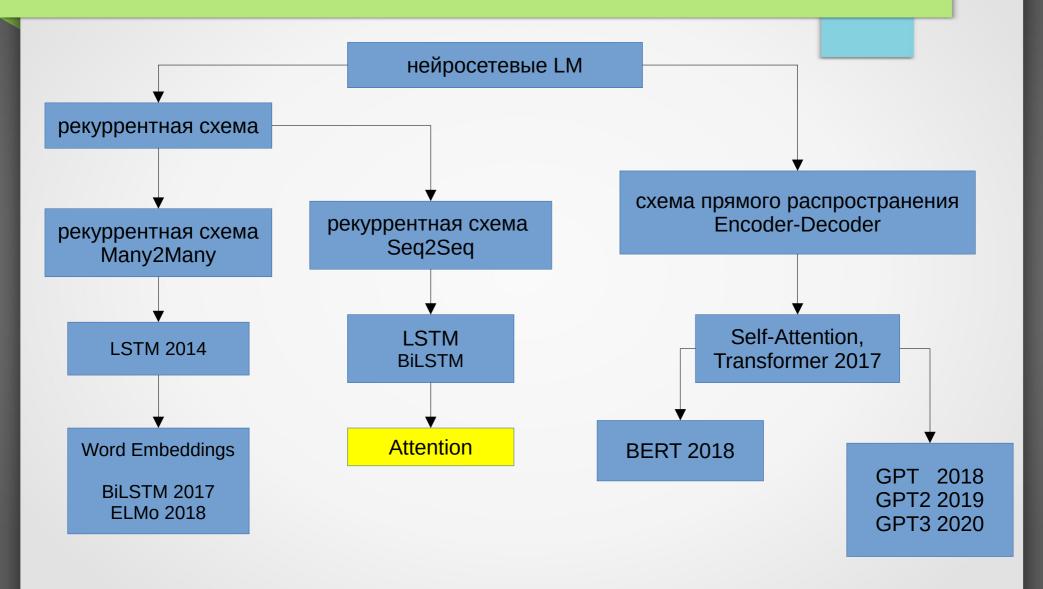
Рекуррентная схема SEQ2SEQ



пара рекуррентных неросетей

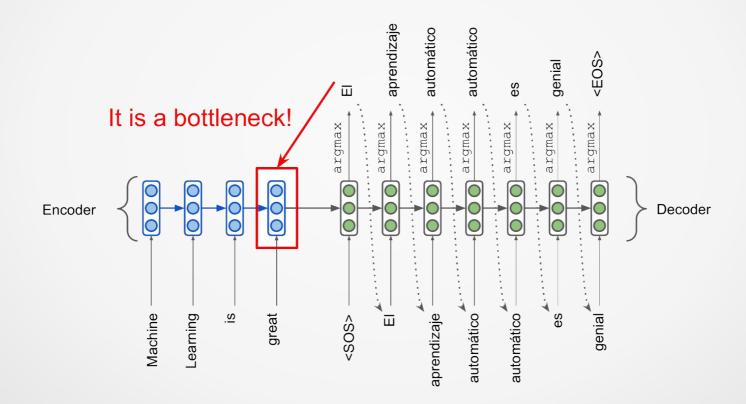
- кодировщик,
 формирует внутреннее представление
- декодировщик, авторегрессионная модель, разворачивает состояние энкодера





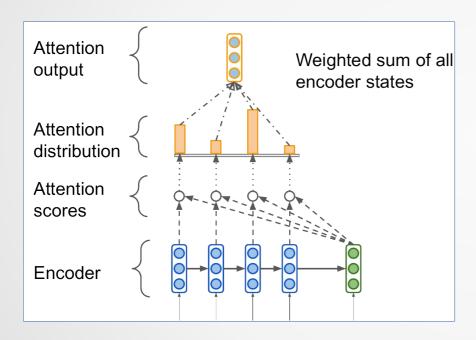
Рекуррентная схема SEQ2SEQ

проблема: модель может "забывать" начальный контекст

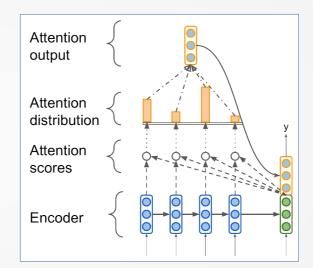


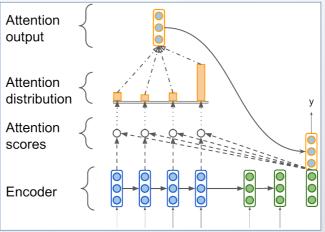
Рекуррентная схема SEQ2SEQ и механизм внимания (Attention)

- считаем коэффициенты внимания
- добавляем к состоянию декодера взвешенную сумму входов



все слова подаём в модель последовательно, схему вычислений трудно распараллелить





Литература

Литература

Борисов E.C. Методы машинного обучения. 2024 https://github.com/mechanoid5/ml_lectorium_2024_I

Борисов E.C. Методы обработки текстов на естественном языке. 2024 https://github.com/mechanoid5/ml_nlp_2024_I

Турдаков Д.Ю. Основы обработки текстов. лекция 3. Языковые модели. ИСП РАН, 2017 https://www.youtube.com/watch?v=seAxPaKw33g

Анатолий Востряков Языковые модели на все случаи жизни, ODS Data Fest 2018 https://www.youtube.com/watch?v=TaCbj1kaDQY

Майоров В.Д. Основы обработки текстов. Лекция 10. Языковвые модели. ИСП РАН, 2021 https://www.youtube.com/watch?v=_8MGdpt4I9M

Нейчев Радослав Машинное обучение 3. Machine translation. Лекторий ФПМИ, 2020 https://www.youtube.com/watch?v=6HibilFua-U